

PRIVACIDAD

Protección de información
personal sensible

PRESENTADO POR:
Jordi Forné

ENTIDAD
Universitat Politècnica de
Catalunya - BARCELONATECH

MÓDULO
Avanzado

Contenidos

1. Introducción
2. Anonimización de bases de datos estadísticos
3. Privacidad diferencial
4. Sistemas de comunicaciones anónimas

Introducción

Jordi Forné (UPC)

Julio 2026

Motivación: Cuestiones éticas

- Privacidad y derechos humanos.
 - **1948.- Declaración Universal de Derechos Humanos**, artículo 12 :

Nadie será objeto de injerencias arbitrarias en su **vida privada**, su familia, su domicilio o su correspondencia, ni de ataques a su honra y reputación. **Toda persona** tiene **derecho** a la protección de la ley contra tales injerencias o ataques.

- Es decir, la privacidad es un **DERECHO FUNDAMENTAL** de los individuos.

Motivación: Cuestiones legales. RGDP

- En mayo de 2018 comenzó a aplicarse el Reglamento General de Protección de Datos (RGPD).
 - En inglés, *General Data Protection Regulation (GDPR)*.
 - Legisla la forma en que se obtienen, almacenan y procesan los datos en los países de la Unión Europea.
 - Da cobertura legal a la privacidad de los ciudadanos europeos.
 - Consolida algunos derechos relacionados con la privacidad, entre ellos:
 - Derecho al borrado
 - Derecho al olvido
- Es decir, garantizar la privacidad es una **OBLIGACIÓN LEGAL** de las empresas y administraciones.

Sanciones previstas por violación de RGPD

- El RGPD establece sanciones significativas para las infracciones, diseñadas para ser efectivas, proporcionadas y disuasorias.
- Las multas se dividen en dos niveles principales, dependiendo de la gravedad de la violación:
 - Multas de Nivel Inferior:
 - Hasta **€10 millones** o el **2% del volumen de negocio anual global** del ejercicio financiero anterior, el que sea mayor.
 - Multas de Nivel Superior (Infracciones más graves):
 - Hasta **€20 millones** o el **4% del volumen de negocio anual global** del ejercicio financiero anterior, el que sea mayor.
- Reflexión:
 - ¿Cuál es el volumen de negocio anual global para BIG TECHS como Google, Facebook, Tiktok, Amazon, ...?
 - ¿A qué cantidad pueden ascender las sanciones?

Algunas multas impuestas por violación de RGPD

- Amazon Europe Core S.a.r.l. - **€746 millones** (julio de 2021)
- Meta Platforms Ireland Limited (Instagram) - **€405 millones** (septiembre de 2022)
- TikTok Limited - **€345 millones** (septiembre de 2023)
- Meta Platforms Ireland Limited (Facebook e Instagram) - **€390 millones** (enero de 2023)
- TikTok Limited - **€530 millones** (2 May 2025) por transferir datos personales de ciudadanos europeos a China (https://www.edpb.europa.eu/news/irish-supervisory-authority-fines-tiktok-eu530-million-and-orders-corrective-measures_en)

(Ver listado en <https://usercentrics.com/knowledge-hub/gdpr-fines/>)

Repercusiones de RGPD

- Desde 2018 las compañías y administraciones están muy motivadas para gestionar los datos de sus usuarios ofreciendo garantías de protección de la privacidad.
 - Al menos en todo lo que queda especificado en la RGPD
- RGPD es probablemente la legislación de privacidad más restrictiva (que mejor protege) a nivel internacional
- Dado que las grandes tecnológicas operan también en Europa, en la práctica RGPD es el **estándar "de facto"** para garantizar privacidad
 - Si se cumple la legislación de la RGPD, probablemente se puede operar sin problemas en cualquier parte del mundo.

Definiciones básicas


- El **anonimato** de un sujeto significa que este no es identificable dentro de un conjunto de sujetos, el conjunto de anonimato.
- Un **seudónimo** es un identificador de un sujeto distinto del nombre real del sujeto.
- La **seudonimización** se define como la sustitución del nombre (u otros identificadores) por un número para imposibilitar o dificultar considerablemente la identificación del titular de los datos.

Anonimización vs Seudonimización (según RGPD)

- Tanto los datos **seudonimizados** como los **anonimizados** sirven para reducir la identificabilidad de los datos.
- La diferencia clave es que los datos **seudonimizados** se pueden recuperar, mientras que los **anonimizados** no se pueden reidentificar.
- Los **datos seudonimizados** se siguen considerando **datos personales** y debe implementarse la **protección del RGPD**.
- Los **datos anonimizados** ya **no se consideran** datos personales.
 - Por lo tanto, el **RGPD no se aplica** a los datos anonimizados.

Modelos de confianza del receptor de la información

- De confianza: **Cifrado y Control de Acceso**
- No de confianza: **Perturbación de la información**



Este curso se centra principalmente en receptores de la información que no son de confianza.



- Privacidad basada en técnicas perturbativas de datos

Dominios de privacidad

- Los dominios de privacidad son áreas donde se pueden aplicar tecnologías de privacidad.
- Algunos dominios de privacidad representativos son:
 - Sistemas de comunicación anónimos
 - Publicación de Datos Estadísticos
 - Sistemas de información personalizados
 - Servicios basados en la ubicación

Sistemas de comunicación anónimos

El objetivo es evitar que un adversario vincule un mensaje saliente con su mensaje de entrada correspondiente.



Publicación de Bases de Datos Estadísticos

- Publicación para análisis posterior de estos datos estadísticos, que muchas veces contienen **INFORMACIÓN PERSONAL SENSIBLE**

Identificadores		Atributos Demográficos			Atributos Confidenciales			
Patient	Sex	Age	Wgt lb	BMI	♥/min	BP mmHg	SpO ₂ %	EKG
Alice Adams	♀	32	143	21.8	81	115/73	97	
Bob Brown	♂	34	135	19.8	112	117/76	99	
Chloe Carter	♀	33	142	22.9	105	129/77	90	
Dave Diaz	♂	43	162	21.9	55	117/76	100	
Eve Ellis	♀	47	169	30.3	92	152/94	93	
Frank Fisher	♂	45	167	23.4	78	120/80	98	

- L. Sweeney, 2000.** El 87% de la población de EE.UU. puede ser IDENTIFICADA INEQUIVOCAMENTE simplemente con la tripleta {Fecha de Nacimiento, Género, Código Postal}, usando en censo de 1990 (más de 248 millones de habitantes).


Sistemas de información personalizados



Muchos servicios Web son personalizados:

- Sistemas de recomendación
- Motores de búsqueda
- Aplicaciones de etiquetado
- Publicidad online


Publicidad Online



La publicidad en línea es ejemplo de sistemas personalizados:

- Es “un pilar” de la economía libre de Internet
- Está integrado en muchos sitios web.
- Por lo tanto, las preocupaciones sobre la privacidad en sistemas de información personalizados afectan prácticamente a toda la navegación web.

Perfiles de usuario



Los perfiles de usuario pueden ser representados mediante:

- Histogramas
- Nubes de etiquetas
- Listas de categorías de interés


Your categories

Below you can edit the interests and inferred demographics that Google has associated with your cookie:


Category	
Beauty & Fitness – Fitness – Yoga & Pilates	Remove
Hobbies & Leisure – Water Activities – Surf & Swim	Remove
Home & Garden – Home Improvement – House Painting & Finishing	Remove
News – Health News	Remove
People & Society – Family & Relationships – Family – Baby Names	Remove
People & Society – Family & Relationships – Family – Parenting – Baby Care	Remove
Sports – Individual Sports - Cycling	Remove
Sports – Individual Sports – Gymnastics	Remove
Demographics – Age – 25-34	Remove
Demographics – Gender – Female	Remove

Servicios basados en la ubicación

La recopilación masiva de información geo-localizada representa un claro riesgo para la privacidad de los usuarios.




Compromiso entre privacidad y utilidad



Consentimiento de usuario

- En todas estas tecnologías, proteger la privacidad del usuario y, al mismo tiempo, mantener la utilidad de los datos que necesariamente se suministran a terceros no confiables surgen como objetivos opuestos.
- Sin embargo, la protección de la información puede aumentar significativamente el consentimiento de usuarios
 - Mayor número de usuarios, mayor utilidad
 - Posibilidad de nuevos servicios
 - Aceptación del cliente



Privacidad sintáctica versus privacidad semántica

- Las nociones sintácticas garantizan una propiedad de privacidad en los **datos anonimizados** (por ejemplo, k -anonimato)
- Las nociones semánticas garantizan una propiedad de privacidad en el **mecanismo de anonimización** de los datos (por ejemplo, privacidad diferencial)



Anonimización de bases de datos estadísticos

Jordi Forné (UPC)

Julio 2026

Protección de bases de datos

- Entorno interactivo

- Los usuarios realizan consultas a una base de datos.
- El concepto de Privacidad Diferencial (DP: *Differential Privacy*) se propuso inicialmente para este escenario.

- Entorno no interactivo

- Se publica una base de datos anonimizada (protegida).
- También conocido en la literatura como Publicación de Datos con Preservación de la Privacidad (PPDP: *Privacy-Preserving Data Publishing*).

Objetivos del control de revelado estadístico

El control de revelado estadístico (SDC: *Statistical Disclosure Control*) se preocupa de:

- El postprocesado de los identificadores indirectos
- de los resultados estadísticos de las encuestas
- que contiene información personal confidencial,
- con el fin de salvaguardar eficazmente el anonimato de los participantes.

Control de revelado estadístico (SDC)

Identificadores		Cuasi-identificadores			Atributos Confidenciales			
Patient	Sex	Age	Wgt lb	BMI	♥/min	BP mmHg	SpO ₂ %	EKG
Alice Adams	♀	32	143	21.8	81	115/73	97	
Bob Brown	♂	34	135	19.8	112	117/76	99	
Chloe Carter	♀	33	142	22.9	105	129/77	90	
Dave Diaz	♂	43	162	21.9	55	117/76	100	
Eve Ellis	♀	47	169	30.3	92	152/94	93	
Frank Fisher	♂	45	167	23.4	78	120/80	98	

Clasificación de atributos

Los atributos incluidos en un conjunto de microdatos se pueden clasificar como:

- **Atributos de identificación**

- Datos que identifican de forma única al encuestado, como nombres, direcciones y números de identificación.
 - Estas variables deben eliminarse del conjunto de datos antes de su publicación.

- **Atributos de identificación indirecta** (también conocidos como **cuasi-identificadores** o **atributos clave**)

- Datos que, combinados, permiten identificar a un encuestado, como el género, la edad, la ocupación, el lugar de residencia y el país de nacimiento.
 - Estas variables son principalmente variables públicas o presentes en bases de datos públicas, como registros.

- **Atributos confidenciales o sensibles**

- Representar los datos que no deben divulgarse como ingresos, historial médico, comportamiento sexual.

Tipos de atributos

Identificadores

Permiten la identificación inequívoca de individuos y deben eliminarse antes de la publicación del conjunto de microdatos.

Este es el caso de los números de DNI, de la seguridad social o los nombres completos.

Cuasi-Identificadores

También llamados atributos clave, son atributos que, en combinación, pueden vincularse a información externa para reidentificar a los encuestado.

Por ejemplo, dirección, género, edad, tipo de trabajo, altura y peso.

Atributos

Información sensible del encuestado.

Como el salario, la religión, la afiliación política, el estado de salud y el rendimiento académico.

Observar que:

- Todos los atributos relevantes realmente contribuyen a delimitar una identidad,
- pero se supone que solo los cuasi-identificadores están públicamente disponibles o son fácilmente inferibles para un individuo. Típicamente son datos demográficos, digamos una dirección en las páginas amarillas o atributos físicos observables.

Clasificación de atributos

Estos atributos también pueden clasificarse como :

- **Categóricos:** toma valores sobre un conjunto finito (por ejemplo, género)
- **Continuos:** se pueden realizar operaciones aritméticas con números reales (por ejemplo, ingresos)


Riesgo de reidentificación en anonimización ingenua

- Desde el punto de vista de la protección de la privacidad, la mera **eliminación de identificadores** en general resulta **insuficiente** en la publicación de conjuntos de microdatos para estudios estadísticos.
- Se ha demostrado de forma famosa¹ que el **87% de la población** de Estados Unidos puede ser **identificada de manera inequívoca** únicamente sobre la base del triplete formado por su **fecha de nacimiento, género y código postal** de cinco dígitos, según datos del censo de **1990**, a pesar de que en ese año Estados Unidos tenía una población de más de **248 millones**.

¹ L. Sweeney, "Uniqueness of simple demographics in the U.S. population," Carnegie Mellon Univ., Sch. Comput. Sci., Data Priv. Lab., Tech. Rep. LIDAP-WP4, Pittsburgh, PA, 2000.

Ataque de enlace (*Linking Attack*)

- El 87% de la población de EE. UU. es identificable de forma única por código postal de 5 dígitos, género y fecha de nacimiento [según datos resumidos del censo de EE. UU. de 1990]
- 53% de la población con fecha de nacimiento, género y ciudad
- Un ataque práctico [Sweeney]



Latanya Sweeney's Attack (1997)

Conjunto de datos de altas hospitalarias de Massachusetts

Medical Data Released as Anonymous

SSN	Name	Ethnicity	Date Of Birth	Sex	ZIP	Marital Status	Problem
		asian	09/27/64	female	02139	divorced	hypertension
		asian	09/30/64	female	02139	divorced	obesity
		asian	04/18/64	male	02139	married	chest pain
		asian	04/15/64	male	02139	married	obesity
		black	03/13/63	male	02138	married	hypertension
		black	03/18/63	male	02138	married	shortness of breath
		black	09/13/64	female	02141	married	shortness of breath
		black	09/07/64	female	02141	married	obesity
		white	05/14/61	male	02138	single	chest pain
		white	05/08/61	male	02138	single	obesity
		white	09/15/61	female	02142	widow	shortness of breath

Conjunto de datos públicos de votantes

Voter List

Name	Address	City	ZIP	DOB	Sex	Party	
.....							
.....							
Sue J. Carlson	1459 Main St.	Cambridge	02142	9/15/61	female	democrat	
.....							

Figure 1: Re-identifying anonymous data by linking to external data





¿Puedes identificar el problema de salud de Sue J. Carlson?

Ejemplo médico hipotético

Identificadores	Cuasi-identificadores				Atributos Confidenciales			
Patient	Sex	Age	Wgt lb	BMI	♥/min	BP mmHg	SpO ₂ %	EKG
Alice Adams	♀	32	143	21.8	81	115/73	97	
Bob Brown	♂	34	135	19.8	112	117/76	99	
Chloe Carter	♀	33	142	22.9	105	129/77	90	
Dave Diaz	♂	43	162	21.9	55	117/76	100	
Eve Ellis	♀	47	169	30.3	92	152/94	93	
Frank Fisher	♂	45	167	23.4	78	120/80	98	

- Ejemplo de signos vitales de algunos pacientes en un quirófano
 - El sexo, la edad, el peso (en libras) y el índice de masa corporal (BMI) son **cuasi-identificadores**.
 - Los **atributos confidenciales** son la frecuencia cardíaca (en latidos por minuto), la presión arterial (BP, en mmHg), la saturación periférica de oxígeno (SpO₂, como porcentaje) y el electrocardiograma (EKG).

Microagregación k-anonima

Identificadores eliminados	Cuasi-identificadores microagregados				Atributos confidenciales			
Patient	Sex ♀	Age	Wgt lb	BMI	♥/min	BP mmHg	SpO ₂ %	EKG
Alice Adams	0.67	33	140	21.5	81	115/73	97	
Bob Brown	0.67	33	140	21.5	112	117/76	99	
Chloe Carter	0.67	33	140	21.5	105	129/77	90	
Dave Diaz	0.33	45	166	25.2	55	117/76	100	
Eve Ellis	0.33	45	166	25.2	92	152/94	93	
Frank Fisher	0.33	45	166	25.2	78	120/80	98	

3-Anonymized
Records

- Los **cuasi-identificadores** dentro de un grupo se **reemplazan** por un **valor representativo común** (por ejemplo, media), rango o categoría.
- El **k-anonimato** es el requisito de que al menos **k registros** compartan una **tupla cuasi-identificadora común** y representativa (perturbada).

k-anonimato

- Cada registro debe ser indistinguible de **al menos** otros $k-1$ registros con respecto al cuasi-identificador
- El **ataque de enlace** no puede ejecutarse con **confianza** $> 1/k$

k-anonimato: Ejemplo

$k=2$ and $QI=\{Race, Birth, Gender, ZIP\}$

Clase de
Equivalencia

	Race	Birth	Gender	ZIP	Problem
t1	Black	1965	m	0214*	short breath
t2	Black	1965	m	0214*	chest pain
t3	Black	1965	f	0213*	hypertension
t4	Black	1965	f	0213*	hypertension
t5	Black	1964	f	0213*	obesity
t6	Black	1964	f	0213*	chest pain
t7	White	1964	m	0213*	chest pain
t8	White	1964	m	0213*	obesity
t9	White	1964	m	0213*	short breath
t10	White	1967	m	0213*	chest pain
t11	White	1967	m	0213*	chest pain

Clasificación de métodos de SDC

- **No perturbativo:** suprime o reduce el detalle sin alterar los datos originales.
- **Perturbativo:** distorsiona el conjunto original de microdatos antes de su publicación.
- **Microdatos sintéticos:** generan datos falsos que conservan ciertas estadísticas o relaciones de los datos originales.

Dependiendo del mecanismo aplicado :

- **Determinista:** Siempre obtenemos el mismo resultado utilizando el mismo conjunto de datos
- **Probabilístico:** Se obtiene una modificación diferente del conjunto de datos cada vez que se aplica el método

Alcanzando k -Anonimato...


Generalización

- Reemplazar los cuasi-identificadores específicos con valores menos específicos hasta obtener k valores idénticos
 - Para atributos categóricos
- Dividir dominios de valores ordenados en intervalos
 - Para atributos continuos

Supresión

- Eliminar algunos registros cuando la generalización causa una pérdida excesiva de información
 - Esto es común con los "*outliers*"

Jerarquías de generalización (atributos categóricos)



Microagregación


- La **microagregación** es un método de perturbación que se aplica típicamente a **variables continuas**.
- Ampliamente utilizado para obtener **k-anonimato**.
- El método consta de dos etapas:
 - Primero, se dividen los registros en **grupos**.
 - Luego, se **asigna** un **valor agregado** a cada variable del grupo (por ejemplo, la media aritmética).
- El reto consiste en agrupar los registros que son "**similares**".

Microagregación

- La k -partición óptima es la que maximiza la homogeneidad dentro del grupo.
 - Cuanto mayor sea la homogeneidad intragrupal, menor será la pérdida de información.
- Un criterio típico para medir la homogeneidad en el agrupamiento es la suma de los errores al cuadrado (SSE: *sum of squared errors*).

$$SSE = \sum_{i=1}^g \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)' (x_{ij} - \bar{x}_i)$$

centroide



MDAV


- La microagregación es (en general) un problema de NP.
 - En general se usan algoritmos heurísticos
- Uno de los algoritmos heurísticos más utilizados para la microagregación de datos numéricos es MDAV (Distancia Máxima al Vector Promedio, *Maximum Distance to Average Vector*).
 - Coste computacional: $O(n^2/k)$
- <https://zonavideo.upc.edu/video/619220fe0210805fcb1c9e56>

Domingo-Ferrer, J., and Mateo-Sanz, J. M. (2002). "Practical data-oriented microaggregation for statistical disclosure control". IEEE Transactions on Knowledge and Data Engineering, 14(1):189-201, 2002.


Otros algoritmos para k-anonimato

- DATAFLY (Sweeney, 1998)
 - Sweeney L. (1998) Datafly: a system for providing anonymity in medical data. In: Lin T.Y., Qian S. (eds) Database Security XI. IFIP Advances in Information and Communication Technology. Springer, Boston, MA.
- INCOGNITO (K. LeFevre; D.J. DeWitt; R. Ramakrishnan, 2005)
 - Kristen LeFevre, David J. DeWitt, Raghu Ramakrishnan, “Incognito: efficient full-domain K-anonymity”. SIGMOD '05: Proceedings of the 2005 ACM SIGMOD international conference on Management of data. June 2005 Pages 49–60.
- MONDRIAN (K. LeFevre; D.J. DeWitt; R. Ramakrishnan, 2006)
 - K. LeFevre, D. J. DeWitt and R. Ramakrishnan, "Mondrian Multidimensional K-Anonymity," 22nd International Conference on Data Engineering (ICDE'06), 2006, pp. 25-25, doi: 10.1109/ICDE.2006.101.
- PCL (Rebollo-Monedero, Forné, Pallarès, Parra-Arnau, 2013).
 - D. Rebollo-Monedero, J. Forné, E. Pallarès, J. Parra-Arnau, “ A modification of the Lloyd algorithm for k-anonymous quantization” . Information Sciences Volume 222, February 2013, Pages 185-202.
- F-MDAV (A. Rodríguez-Hoyos, J. Estrada-Jiménez, D. Rebollo-Monedero, A. Mezher, J. Parra-Arnau, J. Forné, 2020)
 - A. Rodríguez-Hoyos, J. Estrada-Jiménez, D. Rebollo-Monedero, A. Mezher, J. Parra-Arnau, J. Forné, “The Fast Maximum Distance to Average Vector (F-MDAV): An algorithm for k-anonymous microaggregation in big data”. Eng. Appl. Artif. Intell. 90: 103531 (2020)

MDAV vs PCL



(a) MDAV, $\rho = 0$, $\mathcal{D} \simeq 0.141$,
 $k = 4096$.



(b) PCL, $\rho = 0$, $\mathcal{D} \simeq 0.119$
(-16%), $k = 4096$.

Métricas (o nociones) de privacidad

- Nociones sintácticas de privacidad
 - Las nociones sintácticas garantizan una propiedad de privacidad en los datos anonimizados (por ejemplo, k -anonimato)
- Las nociones sintácticas de privacidad usadas en SDC son:
 - k -anonimato¹
 - l -diversidad²
 - t -cercanía³ (t -closeness)

¹ L. Sweeney, "k-Anonymity: A model for protecting privacy", Int. J. Uncertain., Fuzz., Knowl.-Based Syst., vol. 10, no. 5, pp. 557-570, 2002.

² A. Machanavajjhala, J. Gehrke, D. Kiefer, M. Venkitasubramanian, "l-Diversity: Privacy beyond k-anonymity", in Proc. IEEE Int. Conf. Data Eng. (ICDE), Atlanta, GA, Apr. 2006.

³ N. Li, T. Li, S. Venkatasubramanian, "t-Closeness: Privacy beyond k-anonymity and l-diversity", in Proc. IEEE Int. Conf. Data Eng. (ICDE), Istanbul, Turkey, Apr. 2007, pp. 106-115.

k -Anonimato

original table

date of birth

Name	DOB	Gender	Zipcode	Disease
Andre	1/21/76	Female	53715	Heart Disease
Beth	4/13/86	Female	53715	Hepatitis
Carol	2/28/76	Male	53703	Brochitis
Dan	1/21/76	Male	53703	Broken Arm
Ellen	4/13/86	Female	53806	Flu
Eric	2/28/76	Female	53806	Hang Nail

2-anonymous
table

	DOB	Gender	Zipcode	Disease
	*	Female	5371*	Heart Disease
	*	Female	5371*	Hepatitis
	*	Male	5370*	Brochitis
	*	Male	5370*	Broken Arm
	*	Female	538**	Flu
	*	Female	538**	Hang Nail

Limitaciones de k -anonimato

Original microdata					3-anonymous table			
		QID			SA			
		Zipcode	Age	Sex	Disease			
Alice	→	47676	27	F	Diabetes			
		47602	22	F	Diabetes			
		47678	27	M	Diabetes			
Berta	→	47905	43	M	Heart disease			
Naroto	→	47909	52	F	Cancer			
	→	47906	47	M	Cancer			

Ataque de homogeneidad -> I-diversidad

Supongamos que el adversario sabe que la combinación de atributos de cuasi-identificador de Alice es (47676, 27, F). El atacante desconoce cuál de los tres primeros registros corresponde al de Alice, pero descubre que su condición de salud es diabetes.

Ataque de sesgo-> t-closeness

Supongamos que el adversario sabe que la combinación de atributos cuasi-identificadores de Berta es (47909, 52, F). El atacante desconoce cuál de los tres primeros registros corresponde al de Berta, pero descubre que, muy probablemente, su estado de salud es cáncer.

Ataque de inferencia -> Privacidad Diferencial (DP: *Differential Privacy*)

Supongamos que el adversario sabe que la combinación de atributos de cuasi-identificador de Naroto es (47905, 47, M). El atacante descubre que es muy probable que Naroto tenga cáncer, ya que los japoneses tienen una baja incidencia de infartos.

l -Diversidad

- La idea es que los atributos sensibles sean “**diversos**” dentro de cada grupo k -anónimo
- Cada clase de equivalencia tiene al menos l **valores sensibles bien representados**
- Different meanings of “well-represented” values, in addition to distinct l -diversity
- Diferentes significados de valores “bien representados”, además de diferentes definiciones:
 - **l -diversidad distinta**. Hay al menos l valores distintos para el atributo sensible en cada clase de equivalencia. Esto no impide los ataques de inferencia probabilística.
 - **l -diversity** de entropía. La entropía de la distribución de valores sensibles en cada clase de equivalencia es al menos $\log l$

$$H(Z|X = x) = - \sum_z p_{Z|X}(z|x) \log p_{Z|X}(z|x) \geq \log l \quad \text{para todas las clases } x$$

entropía del atributo confidencial Z en la clase equivalente x

parámetro

k -anonimato y l -diversidad

Tabla 6-anónima, 3-diversa

Caucas	787XX	Flu
Caucas	787XX	Shingles
Caucas	787XX	Acne
Caucas	787XX	Flu
Caucas	787XX	Acne
Caucas	787XX	Flu
Asian/AfrAm	78XXX	Flu
Asian/AfrAm	78XXX	Flu
Asian/AfrAm	78XXX	Acne
Asian/AfrAm	78XXX	Shingles
Asian/AfrAm	78XXX	Acne
Asian/AfrAm	78XXX	Flu

Al menos 3 valores diferentes del atributo confidencial


- Su objetivo es proteger contra la divulgación de atributos confidenciales.
- La idea es tener al menos p valores sensibles diferentes del atributo confidencial dentro de cada clase k -anónima.

l -Diversidad: Ejemplo de ataque de sesgo

- Un atributo sensible con dos valores: covid+(1%)/covid-(99%)
- Supongamos que una clase tiene el mismo número de covid+ y covid-.
- Cualquier persona de la clase tiene un 50% de probabilidad de ser covid+ (compárese con el 1% de probabilidad en la población general).

Problema: Cuando la distribución general está sesgada, satisfacer la l -diversidad no impide la divulgación de atributos (con alta probabilidad)

Limitaciones de la l-diversidad



- Propenso a los ataques de asimetría

Privacidad t-cercanía (*t-closeness*)


Caucas	787XX	Flu
Caucas	787XX	Shingles
Caucas	787XX	Acne
Caucas	787XX	Flu
Caucas	787XX	Acne
Caucas	787XX	Flu
Asian/AfrAm	78XXX	Flu
Asian/AfrAm	78XXX	Flu
Asian/AfrAm	78XXX	Acne
Asian/AfrAm	78XXX	Shingles
Asian/AfrAm	78XXX	Acne
Asian/AfrAm	78XXX	Flu

Distribución general

- La idea es que la **distribución** de atributos confidenciales dados los atributos clave perturbados observados debe ser cercana a la **distribución general** del atributo confidencial.

$$|d(p_{Z|X}(z|x), p_Z(z))| \leq t$$


confidencial grupo o clase de equivalencia



Preguntas sobre SDC y anonimización de bases de datos

Jordi Forné (ENTEL)

Alice es una encuestada que envía su información a X mediante una conexión cifrada (mediante el protocolo https). X recopila datos de diferentes usuarios, genera una base de datos y luego publica una versión anonimizada de esta (mediante un algoritmo de anonimización como MDAV). Finalmente, Y accede a la base de datos anonimizada para obtener información estadística valiosa. Respecto al modelo de confianza, ¿cuál de las siguientes afirmaciones es verdadera?



- a) Alice debe confiar en X.
- b) Alice debe confiar en Y.
- c) Alice debe confiar en cualquiera que esté escuchando el canal de comunicación (como lo hace Eve).
- d) Alicia no está obligada a confiar en ninguna entidad externa, es decir, ni en X ni en Y.

En SDC, ¿cuál es el principal problema de privacidad que surge al publicar los cuasi-identificadores junto con los atributos confidenciales de los encuestados?

- a) Los atributos clave son información sensible que debe mantenerse en secreto.
- b) Publicarlos no implica riesgos para la privacidad.
- c) No es posible publicar los atributos confidenciales de forma segura a menos que estén cifrados.
- d) Un atacante podría vincular los atributos confidenciales con la identidad de los encuestados.

En una base de datos de SDC, la columna “DNI” sería:

- a) Un atributo confidencial.
- b) Un identificador.
- c) Un cuasi-identificador.
- d) Ninguna de las anteriores.

En una base de datos de SDC, la columna "salario" sería:

- a) Un atributo confidencial.
- b) Un identificador.
- c) Un cuasi-identificador.
- d) Ninguna de las anteriores.

En una base de datos de SDC, la columna “edad” sería:

- a) Un atributo confidencial.
- b) Un identificador.
- c) Un cuasi-identificador.
- d) Ninguna de las anteriores.

Respecto del k-anonimato, ¿cuál de las siguientes afirmaciones es verdadera?

- a) Valores altos de k implican una mayor protección de la privacidad, pero generalmente causan una mayor pérdida de utilidad de los datos.
- b) Valores bajos de k implican una mayor protección de la privacidad, pero generalmente causan una mayor pérdida de utilidad de los datos.
- c) Valores altos de k implican una mayor protección de la privacidad y generalmente causan una menor pérdida de utilidad de los datos.
- d) Valores altos de k implican una menor protección de la privacidad, y la pérdida de utilidad de los datos generalmente no depende de k .

Si publicamos el PESO y el ATRIBUTO CONFIDENCIAL de la Tabla (no publicamos las demás columnas):

NAME	AGE	GENDER	WEIGHT	CONFIDENTIAL ATTRIBUTE
Arlet	4	Female	[16-20]	A
Berta	4	Female	[16-20]	A
Clara	4	Female	[16-20]	B
Derek	3	Male	[11-15]	B
Enzo	4	Male	[11-15]	C
Fiona	3	Female	[11-15]	C

- a) Ofrecemos 3-anonimato y 2-diversidad doble.
- b) Ofrecemos 2-anonimato doble y 3-diversidad triple.
- c) Ofrecemos 3-anonimato, pero no l-diversidad.
- d) Ofrecemos 2-anonimato doble, pero no l-diversidad.

Si publicamos la EDAD, el PESO y el ATRIBUTO CONFIDENCIAL (no publicamos las demás columnas):

NAME	AGE	GENDER	WEIGHT	CONFIDENTIAL ATTRIBUTE
Arlet	4	Female	[16-20]	A
Berta	4	Female	[16-20]	A
Clara	4	Female	[16-20]	B
Derek	3	Male	[11-15]	B
Enzo	4	Male	[11-15]	C
Fiona	3	Female	[11-15]	C

- a) Ofrecemos 2-anonimato, pero no l-diversidad.
- b) Ofrecemos 2-anonimato, con 2-diversidad.
- c) No ofrecemos ni k-anonimato ni l-diversidad
- d) Ofrececmos 3-anonimato.

Privacidad Diferencial

Jordi Forné (UPC)


Julio 2026

Privacidad Diferencial (DP)

Escenario:

- **Base de datos:** compuesta por registros individuales (es decir, microdatos)
- **Curador:** tiene como objetivo proteger la privacidad de los individuos; es una entidad de confianza
- **Analista o usuario de datos:** desea realizar cálculos sobre la base de datos; es el atacante

Hipótesis: una respuesta a una consulta estadística protege la privacidad de los individuos en la base de datos si no revela ninguna información que sea específica de ningún individuo.



Privacidad Diferencial (DP)

- Una computación protege la privacidad de los individuos en los datos si su resultado no revela ninguna información que sea específica de ningún interesado individual.
- La privacidad diferencial formaliza esta intuición como una definición matemática.
- Adoptada por grandes empresas tecnológicas.




Privacidad Diferencial (DP)

- La privacidad diferencial fue desarrollada para permitir la creación de estadísticas útiles mientras se mantiene la privacidad del individuo.
- Para proteger a un individuo en un conjunto de datos, se añade ruido aleatorio al resultado de una consulta estadística
- La magnitud del ruido aleatorio requerido es proporcional a la sensibilidad de la función de la consulta estadística.
- La sensibilidad de una función de consulta es la mayor diferencia en el resultado que un cambio en el conjunto de datos subyacente puede introducir.


Privacidad Diferencial (DP)

Indistinguibilidad entre dos escenarios



Differential privacy

- La DP (Privacidad Diferencial) tiene como objetivo proteger la privacidad de Alice en el escenario del mundo real de tal manera que se asemeje a la protección de privacidad que ella disfruta en el escenario de exclusión voluntaria.
- La garantía se asegura a cualquier individuo en la base de datos.



Bases de datos adyacentes

- DP protege bases de datos ADYACENTES:
- BBDD Adyacentes: Aquellas que difieren en un único registro
 - Bases de datos ilimitadas (*unbounded*)
 - Bases de datos limitadas (*bounded*)

Unbounded

Demographic Attributes			Confidential Attributes					Demographic Attributes			Confidential Attributes				
Sex	Age	Wgt lb	BMI	h /m in	BP mmHg	SpO ₂ %		Sex	Age	Wgt lb	BMI	h /m in	BP mmHg	SpO ₂ %	
	32	143	21.8	81	115/73	97			32	143	21.8	81	115/73	97	
	34	135	19.8	112	117/76	99			34	135	19.8	112	117/76	99	
	33	142	22.9	105	129/77	90			33	142	22.9	105	129/77	90	
	43	162	21.9	55	117/76	100			43	162	21.9	55	117/76	100	
	47	169	30.3	92	152/94	93			47	169	30.3	92	152/94	93	
									45	167	23.4	78	120/80	98	

D_1 D_2

Bounded

Demographic Attributes			Confidential Attributes					Demographic Attributes			Confidential Attributes				
Sex	Age	Wgt lb	BMI	h /m in	BP mmHg	SpO ₂ %		Sex	Age	Wgt lb	BMI	h /m in	BP mmHg	SpO ₂ %	
	32	143	21.8	81	115/73	97			32	143	21.8	81	115/73	97	
	34	135	19.8	112	117/76	99			34	135	19.8	112	117/76	99	
	31	132	24.2	110	123/99	94			23	120	21.1	87	111/92	98	
	43	162	21.9	55	117/76	100			43	162	21.9	55	117/76	100	
	47	169	30.3	92	152/94	93			47	169	30.3	92	152/94	93	

y y'

Definición formal de ϵ -Privacidad Diferencial

Una función (o mecanismo) aleatoria $\mathcal{M} : \mathcal{D} \rightarrow \mathcal{R}$ (que mapea un conjunto de datos D a un rango de posibles resultados $\mathcal{R}$) proporciona ϵ -privacidad diferencial si para cualquier par de conjuntos de datos adyacentes $D_1, D_2 \in \mathcal{D}$ (que difieren en un único registro) y para cualquier subconjunto $S \subseteq \mathcal{R}$ de resultados posibles, se cumple que:

$$P[\mathcal{M}(D_1) \in S] \leq e^\epsilon \cdot P[\mathcal{M}(D_2) \in S]$$

- $\mathcal{M}$ es el mecanismo aleatorio (el algoritmo de privacidad diferencial) que toma un conjunto de datos y produce un resultado.
- $\mathcal{D}$ es el espacio de todos los posibles conjuntos de datos.
- $\mathcal{R}$ es el espacio de todos los posibles resultados del mecanismo.
- D_1 y D_2 son **conjuntos de datos adyacentes** (también llamados "vecinos"). Esto significa que D_1 y D_2 son idénticos excepto por la presencia o ausencia de un único registro de un individuo.
- S es cualquier subconjunto de resultados posibles de $\mathcal{M}$.
- $P[\cdot]$ denota la probabilidad de un evento.
- ϵ (épsilon) es el **parámetro de privacidad**. Un valor de ϵ pequeño significa una mayor privacidad. Cuanto más pequeño es ϵ , más difíciles son de distinguir los resultados de $\mathcal{M}$ en conjuntos de datos D_1 y D_2 .

Algunos comentarios sobre ϵ -DP


Una función (o mecanismo) aleatoria $\mathcal{M} : \mathcal{D} \rightarrow \mathcal{R}$ (que mapea un conjunto de datos D a un rango de posibles resultados R) proporciona ϵ -privacidad diferencial si para cualquier par de conjuntos de datos adyacentes $D_1, D_2 \in \mathcal{D}$ (que difieren en un único registro) y para cualquier subconjunto $S \subseteq \mathcal{R}$ de resultados posibles, se cumple que:

$$P[\mathcal{M}(D_1) \in S] \leq e^\epsilon \cdot P[\mathcal{M}(D_2) \in S]$$

- ϵ controla el grado en que D_1 y D_2 pueden distinguirse
 - Cuanto **mayor es ϵ** , **menor** es la **privacidad**.
- La DP es un criterio de privacidad en el **peor de los casos**.
- La DP puede proteger contra un atacante que lo **sabe todo excepto** los datos objetivo del individuo.
- Se necesita una **gran cantidad de ruido** para aplicar la DP, lo que causa un **impacto** significativo en la **utilidad de los datos**.


Respuesta aleatorizada

- DP refuerza la **privacidad** al introducir la **aleatorización**
- Protocolo de **respuesta aleatorizada** (Warner, 1965)
 - Método de investigación utilizado en entrevistas de encuesta.
 - Los participantes responden a preguntas sensibles manteniendo la confidencialidad.
 - Estimación de la proporción de respuestas afirmativas, garantizando una **negación plausible**.



Respuesta aleatorizada

- Desde el punto de vista del participante y con una moneda justa (cara y cruz equiprobables).
- Este protocolo aleatorizado satisface $\log 3$ -DP.




Demostración

X r.v. true answer

Y r.v. R.R. output

$X, Y \in \{0, 1\}$



$$\Pr\{Y = 0|X = 0\} = \Pr\{\text{"tails in first flip"}\} + \Pr\{\text{"H and T"}\} = \frac{1}{2} + \frac{1}{4} = \frac{3}{4}$$

$$\Pr\{Y = 1|X = 1\} = \Pr\{\text{"tails in first flip"}\} + \Pr\{\text{"H and H"}\} = \frac{3}{4}$$

$$\Pr\{Y = 0|X = 1\} = \Pr\{Y = 1|X = 0\} = \frac{1}{4}$$

No decir la verdad

Demostración

$$X, X'$$

$$X = \neg X'$$


$$\begin{array}{l} \begin{array}{l} Y=0 \\ \text{"para todas las salidas"} \\ Y=1 \end{array} \rightarrow \frac{\Pr\{Y=0|X\}}{\Pr\{Y=0|X'\}} = \left\{ \begin{array}{l} \frac{\Pr\{Y=0|X=0\}}{\Pr\{Y=0|X'=1\}} = \frac{3/4}{1/4} = 3, \quad \text{if } X=0 \\ \frac{\Pr\{Y=0|X=1\}}{\Pr\{Y=0|X'=0\}} = \frac{1/4}{3/4} = 1/3, \quad \text{if } X=1 \end{array} \right. \\ \frac{\Pr\{Y=1|X\}}{\Pr\{Y=1|X'\}} = \left\{ \begin{array}{l} \frac{\Pr\{Y=1|X=0\}}{\Pr\{Y=1|X'=1\}} = 1/3, \quad \text{if } X=0 \\ \frac{\Pr\{Y=1|X=1\}}{\Pr\{Y=1|X'=0\}} = 3, \quad \text{if } X=1 \end{array} \right. \end{array}$$

"para todas las bases de datos adyacentes"

$$1/3 \leq \cdot \leq 3 \Rightarrow (\log 3)\text{-DP}$$

Mecanismo de Laplace

- La respuesta aleatorizada es un mecanismo local: no es necesario confiar en el recopilador de datos.
- Un enfoque diferente es un recopilador y curador de datos confiable.
- Ejemplo de mecanismo de Laplace para calcular la proporción de respuestas afirmativas a una consulta sensible.




Mecanismo de Laplace

El curador hace lo siguiente:

- Recoge las respuestas verdaderas (YES/NO $\Leftrightarrow$ 1/0) de los n participantes
- Calcula la proporción real de respuestas verdaderas $\bar{X} = 1/n \sum_i X_i$
- genera una muestra aleatoria N de una distribución de Laplace con parámetros $\mu = 0, b = \frac{1}{\epsilon n}$.
- Calcula $Z = \bar{X} + N$


Este mecanismo de Laplace que calcula la proporción de respuestas Sí **satisface ϵ -DP**

$$f(x; \mu, b) = \frac{1}{2b} \exp \left(-\frac{|\mu - X|}{b} \right)$$




Perturbación de entrada vs. Perturbación de salida

Perturbación de entrada (ej: respuesta aleatorizada)



Perturbación de salida

El mecanismo de Laplace pertenece a una clase de mecanismos llamados **perturbación de salida** frente a perturbación de entrada.



- La sensibilidad de una función de consulta es el cambio máximo posible en el resultado de esa función cuando se añade o se elimina un único registro de un individuo en el conjunto de datos.
- Esencialmente, mide cuánto impacto puede tener la información de un solo individuo en el resultado final de la consulta.
- Cuanto mayor sea la sensibilidad de la función, mayor aleatorización (ruido) se tendrá que introducir para garantizar un cierto nivel de privacidad.

Dada una función de consulta $f : \mathcal{D} \rightarrow \mathbb{R}^k$ que mapea un conjunto de datos $D \in \mathcal{D}$ (donde $\mathcal{D}$ es el espacio de conjuntos de datos) a un vector de k valores reales (por ejemplo, el resultado de k preguntas estadísticas), la sensibilidad L_1 (L1-sensitivity) de la función f se define como:

$$\Delta f = \max_{D_1, D_2 \text{ adyacentes}} \|f(D_1) - f(D_2)\|_1$$

- f es la función de consulta o el cálculo para el cual queremos garantizar la privacidad diferencial.
- D_1 y D_2 son conjuntos de datos adyacentes. Como se mencionó, esto significa que D_1 y D_2 difieren en un único registro de un individuo (es decir, D_2 se obtiene de D_1 añadiendo o eliminando un solo registro).
- $\|\cdot\|_1$ denota la norma L_1 (o norma de Manhattan), que se calcula como la suma de los valores absolutos de las diferencias entre los elementos correspondientes de los vectores resultantes. Si $y = (y_1, \dots, y_k)$ y $z = (z_1, \dots, z_k)$, entonces $\|y - z\|_1 = \sum_{i=1}^k |y_i - z_i|$.

- La magnitud del ruido aleatorio requerido es proporcional a la sensibilidad de la función de consulta estadística.
- La sensibilidad de una función de consulta representa la mayor diferencia en el resultado que puede introducir un cambio en el conjunto de datos subyacente.
- Para proporcionar DP para una función de consulta que funcione en cualquier conjunto de datos, la sensibilidad calculada debe ser independiente del conjunto de datos subyacente y depender únicamente de la función de consulta.
- Esto se conoce como **sensibilidad global** ($GS(f)$).
 - Vs. **sensibilidad local**, donde la sensibilidad se calcula en función de la base de datos utilizada.

Sensibilidad Local vs. Global (Ejemplo)


- Suponga una función que calcula la edad media las personas que estamos en esta aula
 - ¿Cuál sería la sensibilidad global de esta función?
 - ¿Cuál sería la sensibilidad local en nuestra aula contando únicamente a los estudiantes?
 - ¿Y si contamos a todos los presentes en el aula?
- Suponga una función que calcula el porcentaje de mujeres en esta aula
 - ¿Cuál sería la sensibilidad global de esta función?
 - ¿Cuál sería la sensibilidad local en nuestra aula?

Mecanismo de Laplace

Para cualquier función numérica

El curador hace los siguiente:

- Calcula la función $f(x)$
- Generar un valor aleatorio N extraído de una distribución de Laplace con parámetros
 - $\mu = 0$
 - $b = \frac{GS(f)}{\epsilon}$
- Calcula $Z = f(x) + N$
- Devuelve Z





Privacidad Diferencial Aproximada

- La **Privacidad Diferencial Aproximada**, formalmente conocida como (ϵ, δ) -DP, es una relajación de la definición más estricta de ϵ -DP.
- Fue introducida para hacer la Privacidad Diferencial **más aplicable en ciertos escenarios prácticos** y para permitir el uso de mecanismos de ruido que no cumplen estrictamente la ϵ -Privacidad Diferencial (como el mecanismo de **ruido Gaussiano**).
- **δ (delta)**: Este es el parámetro que introduce la "aproximación". Representa una **pequeña probabilidad** de que la garantía de privacidad de ϵ **no se cumpla**.

Una función (o mecanismo) aleatoria $\mathcal{M} : \mathcal{D} \rightarrow \mathcal{R}$ proporciona (ϵ, δ) -privacidad diferencial si para cualquier par de conjuntos de datos adyacentes $D_1, D_2 \in \mathcal{D}$ (que difieren en un único registro) y para cualquier subconjunto $S \subseteq \mathcal{R}$ de resultados posibles, se cumple que:

$$P[\mathcal{M}(D_1) \in S] \leq e^\epsilon \cdot P[\mathcal{M}(D_2) \in S] + \delta$$

Ruido Gaussiano vs. Laplaciano



Mecanismo Gaussiano

- El mecanismo gaussiano es una alternativa al mecanismo laplaciano, que consiste en añadir ruido gaussiano en lugar de ruido laplaciano.
- El mecanismo gaussiano no satisface ϵ -DP puro, pero sí satisface (ϵ, δ) -DP.
- Según el mecanismo gaussiano, para una función real $f(x)$, la siguiente definición de $m(x)$ satisface (ϵ, δ) -DP:

$$m(x) = f(x) + N(\sigma^2), \quad \text{donde } \sigma^2 = \frac{2 \text{GS}(f)^2 \log(\frac{1.25}{\delta})}{\epsilon^2}$$

Preguntas sobre Privacidad Diferencial

Jordi Forné (ENTEL)

Con respecto a la privacidad diferencial (DP) y el k-anonimato, ¿cuál de las siguientes afirmaciones es verdadera?

- a) En ϵ -DP, un valor mayor de ϵ implica una mayor garantía de privacidad.
- b) El k-anonimato generalmente causa una mayor pérdida de utilidad de los datos que la Privacidad Diferencial.
- c) En ϵ -DP, un valor mayor de ϵ generalmente implica una menor pérdida de utilidad de los datos.
- d) Dado que el k-anonimato protege contra ataques de conocimiento de fondo, es una métrica de privacidad más sólida que la Privacidad Diferencial.

Al implementar el mecanismo laplaciano, ¿cuál es el modelo de confianza aplicado para la privacidad diferencial?

- a) Los usuarios solo deben confiar en el propietario de la base de datos.
- b) Los usuarios solo deben confiar en el curador.
- c) Los usuarios deben confiar tanto en el propietario como en el curador, pero no en el analista.
- d) Los usuarios no están obligados a confiar en ninguna otra parte.

Al implementar el mecanismo de respuesta aleatorizada, ¿cuál es el modelo de confianza aplicado para la privacidad diferencial?

- a) Los usuarios solo deben confiar en el propietario de la base de datos.
- b) Los usuarios solo deben confiar en el curador.
- c) Los usuarios deben confiar tanto en el propietario como en el curador, pero no en el analista.
- d) Los usuarios no están obligados a confiar en ninguna otra parte.

En la privacidad diferencial, ¿qué significa "bases de datos vecinas"?

- a) Bases de datos que se almacenan en el mismo servidor.
- b) Bases de datos que difieren en un solo registro.
- c) Bases de datos que garantizan un valor pequeño de ϵ .
- d) Bases de datos que se encuentran en el mismo lugar que el curador.

Sea X un conjunto de datos, f una función de consulta sobre X y Z la salida del mecanismo de Laplace a $f(X)$. Si Z satisface la privacidad diferencial ε , ¿cuál de las siguientes afirmaciones es verdadera?

- a) Cuanto mayor sea ε , mayor será la protección de la privacidad que ofrece Z .
- b) Para un ε fijo, cuanto menor sea la sensibilidad de f , mayor será la varianza del ruido de Laplace añadido a $f(X)$.
- c) Para un ε fijo, cuanto mayor sea la sensibilidad de f , mayor será la varianza del ruido de Laplace añadido a $f(X)$.
- d) Cuanto mayor sea ε , mayor será la pérdida de utilidad de los datos

Para una base de datos con 30 usuarios, ¿cuál de las siguientes consultas sobre el peso de los usuarios tiene mayor sensibilidad?

- a) El peso máximo de los usuarios.
- b) El peso promedio de los usuarios.
- c) La mediana del peso de los usuarios.
- d) Dado que todas las consultas son para la misma base de datos, todas tienen la misma sensibilidad.

Para una base de datos con 20 usuarios, ¿cuál de las siguientes consultas sobre la edad de los usuarios tiene menor sensibilidad?


- a) La edad máxima de los usuarios.
- b) La edad promedio de los usuarios.
- c) La edad mediana de los usuarios.
- d) Dado que todas las consultas son para la misma base de datos, todas tienen la misma sensibilidad.

Sistemas de comunicaciones anónimas

Jordi Forné (UPC)

Julio 2026

Ataques de ANÁLISIS DE TRÁFICO




El objetivo es evitar que un adversario vincule un mensaje saliente con su mensaje de entrada correspondiente.

Sistemas de comunicaciones anónimas de alta latencia frente a baja latencia




- Sistemas de comunicación anónima de alta latencia
 - Redes de mezcla (Mix networks)
- Sistemas de comunicación anónima de baja latencia
 - Crowds
 - Enrutamiento cebolla (*Onion Routing* - TOR)

Redes de Mezcla (*Mix Networks*)




Redes de Mezcla (*Mix Networks*)

- Ejemplo: Mezclador por umbral de lotes (*threshold pool mix*)




- Robustos frente a ataques de temporización (*timming attacks*)
- Retardo máximo no acotado


Protocolo colaborativo para sistemas de comunicación anónimas de baja latencia




Protocolo colaborativo para sistemas de comunicación anónimas de baja latencia




Protocolo colaborativo para sistemas de comunicación anónimas de baja latencia




Protocolo colaborativo para sistemas de comunicación anónimas de baja latencia




Protocolo colaborativo para sistemas de comunicación anónimas de baja latencia




Protocolo colaborativo para sistemas de comunicación anónimas de baja latencia




Enrutamiento cebolla (TOR: The Onion Router)




Enrutamiento cebolla (TOR: The Onion Router)



Enrutamiento cebolla (TOR: The Onion Router)



Enrutamiento cebolla (TOR: The Onion Router)



Preguntas sobre sistemas de comunicaciones anónimas

Jordi Forné (UPC)


Julio 2025

¿Cuál de los siguientes es un sistema de comunicación anónimo de alta latencia?

- a) TOR (*The Onion Router*).
- b) Una red de mezcla (*mix network*).
- c) Crowds.
- d) Ninguna de las anteriores.

Tenemos un *threshold pool mix* con un tamaño de grupo $n=5$ que envía a su salida $k=3$ mensajes en cada ronda (véase la Figura). En cada ronda, el *mix* selecciona aleatoriamente k de los n mensajes almacenados y los envía (suponga que k mensajes nuevos entran en el *mix* inmediatamente después de vaciarse). La operación se repite cada 3 segundos. Para un mensaje dado, la probabilidad de permanecer en el *mix* durante más de 10 segundos es:

- a) $4/25$
- b) $8/125$
- c) $9/25$
- d) $27/125$



Con respecto a TOR, ¿cuál de las siguientes afirmaciones es verdadera?

- a) El circuito TOR está compuesto por tres repetidores TOR (enrutadores) diferentes.
- b) TOR es un sistema de comunicación anónimo de alta latencia.
- c) El uso de TOR no añade ningún retraso al tiempo de conexión a un servidor.
- d) Si un solo nodo en la red TOR es malicioso, la privacidad de los usuarios de TOR se ve gravemente afectada.

Con respecto a Crowds, ¿cuál de las siguientes afirmaciones es verdadera?

- a) El retraso máximo está limitado.
- b) El número máximo de nodos que retransmiten un mensaje es tres.
- c) Cuanto menor sea la probabilidad de reenvío al servidor, mayor será el retraso promedio.
- d) Si un solo nodo es malicioso, la privacidad de los demás usuarios se ve gravemente afectada.

¿Preguntas?

- Podéis contactar conmigo a través de mi correo electrónico: jordi.forne@upc.edu.

